Постановка задачи

Требуется разработать чат-бота, который должен вести диалог как определенный персонаж сериала, имитируя стиль и манеру конкретного персонажа сериала.

Github προεκτα: https://github.com/YurezSml/MIPT_NLPGener_HW2/

Обученная модель: https://huggingface.co/yurezsml/phi2_chan

Colab с обучением чат-бота:

https://colab.research.google.com/drive/1bIn2r_c95wnVgJnyrt0x5CwezHYp6cs2

Colab с запуском чат-бота:

https://colab.research.google.com/drive/1IaFwWL12LMLIdNgq9u1QCkxL87_a9GAx

Описание и анализ данных данных

В качестве рассматриваемого сериала был выбран сериал «Друзья»

Источник данных: https://www.kaggle.com/datasets/gopinath15/friends-netflix-script-data

Датасет состоит из 5 столбцов

Text – реплика персонажа и технический текст

Speaker – персонаж, говорящий реплику

Episode – номер и название эпизода

Season – номер сезона

Show – название шоу

Всего датасет содержит 69974 записи. Как будет видно далее, из анализа, не все они являются репликами персонажей, часть можно отнести к техническим записям, связанным с рекламными вставками, окончанием серии и т.д. Несколько записей исходного датасета приведены на рисунке 1.

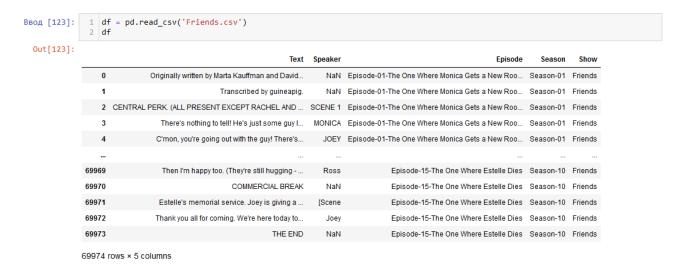


Рисунок 1 – Исходный датасет, состояние до обработки

В ходе анализа и первичной обработки датасета все имена авторов реплик были приведены к одному виду. В датасете обнаружены пропущенные значения для поля с авторами реплик (6284), в ходе анализа было принято решение использовать часть из них в качестве возможных разделителей при разбиении датасета на несвязанные диалоги. Остальные записи с пропущенными авторами реплик были удалены, как разрывающие контекст внутри диалога. Кроме того, в качестве разделителей между диалогами были приняты специальные отметки в поле 'Text'.

Результаты анализа и первичной обработки представлены в файле https://github.com/YurezSml/MIPT_NLPGener_HW2/blob/main/Analysys.ipynb

Подготовка данных

В результате первичной обработки был подготовлен датасет, состоящий из двух полей:

Text – реплика персонажа и технический текст

Speaker – персонаж, говорящий реплику

Независимые или слабо зависимые по контексту диалоги отделены с помощью разделителя 'break' в поле 'Speaker' (Рисунок 2). Нельзя говорить о полной независимости диалогов друг от друга т.к. возможно продолжение общего контекста как через несколько диалогов, так и в разных сериях. Чтобы устранить это и сделать максимально связный контекстом датасет с репликами требуется значительное количество времени, ручного труда и погружение в сюжет.

	lext	Speaker
0	central perk.	break
1	there's nothing to tell! he's just some guy i \dots	monica
2	c'mon, you're going out with the guy! there's \dots	joey
3	so does he have a hump? a hump and a hairpiece?	chandler
4	wait, does he eat chalk?	phoebe
63484	yeah, yeah, oh!	ross
63485	oh! oh, i'm so happy.	rachel
63486	then i'm happy too.	ross
63487	estelle's memorial service. joey is giving a s	break
63488	thank you all for coming. we're here today to	joey

63489 rows × 2 columns

Рисунок 2 – Датасет после первичной обработки

Полученный датасет позволяет выбрать реплики любого из персонажей в качества объекта для обучения. В своей работе я выбрал Чендлера (chandler), поскольку его реплики и шутки являются одними из самых ярких в сериале и выделяются на фоне остальных. Реплики персонажей преобразовывались в датасет для обучения следующим образом: сначала записывались все реплики, предшествующие реплике выбранного персонажа, без разделения на других пресонажей, далее записывалась реплика персонажа. Процедура повторялась до тех пор, пока не была достигнута метка break или заданная глубина контекста СОNT_DEPTH. Если диалог начинается с реплики выбранного персонажа, она не добавлялась в итоговый датасет т.к. у нее нет предшествующей реплики. На рисунке 3 представлено распределение количества реплик в зависимости от глубины контекста диалога. Дополнительное исследование показало, что максимальный из диалогов имеет 84 предшествующих пары вопрос-ответ.

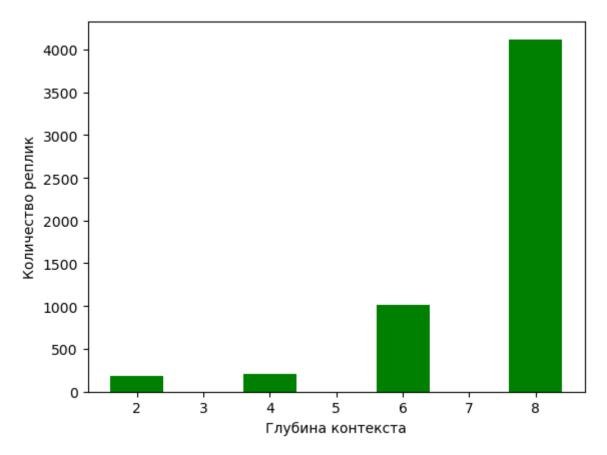


Рисунок 3 – Количество реплик от глубины контекста диалогов в итоговом датасете

Архитектура и обучение модели

В качестве модели для дообучения я выбрал Phi-2 от Microsoft. Выбор обусловлен возможностью дообучения модели на бесплатных мощностях google colab. Архитектура обучения модели представлена на рисунке 4. При этом дообучение проводилось с использованием Peft, дообучение проводилось только для последних слоев модели.

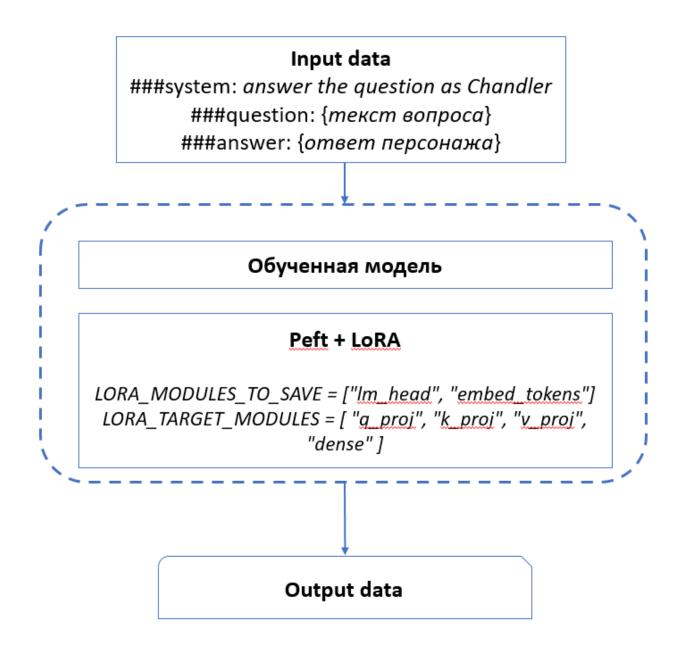


Рисунок 4 – Архитектура обучения модели

При подготовке датасета для обучения с помощью тегов ###question и ###answer отделялись реплики, соответствующие вопросам и ответам в контексте.

Модель обучалась одну эпоху, обучение заняло 1.5часа. Это связано с ограничениями по времени предоставления бесплатных мощностей в google colab. Более длительное обучение скорее всего позволило бы улучшить качество ответов. Гиперпараметры для обучения подбирались исходя из нескольких критериев:

- 1. доступная в google colab память
- 2. желание сохранить адекватный размер батча
- 3. стремление уменьшить галюцинирование результатов.

На рисунке 5 представлен график обучения модели для одной из попыток. Полный набор графиков обучения представлен в проекте по ссылке:

https://wandb.ai/yurezsml mipt/NLPGener HW2. Коллаб с обучением модели находится по ссылке: https://colab.research.google.com/drive/1bIn2r_c95wnVgJnyrt0x5CwezHYp6cs2.

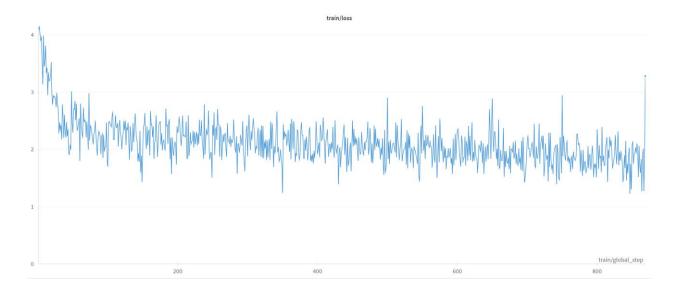


Рисунок 5 – График обучения модели

Уменьшение галюцинирования модели и пример улучшения фактологической связности и валидация модели

Для уменьшения галюцинирования результата использовались следующие методы:

- 1. регуляризация путем сокращения весов weight_decay.
- 2. введение подсказки-инструкция с тегом ###system, указывающей модели что нужно отвечать в стиле обученного персонажа.
- 3. введение в запрос дополнительного контекста с информацией о персонаже исходя из вопроса в чате и информации, полученной со страницы Wikipedia о нем. Контекст вводится перед вопрос и усиливается именем персонажа.

На рисунках 6 и 7 представлены результаты до улучшения фактологической связности путем введения дополнительного контекста и после. Видно, что ответы стали фактически верными и соответствовать отношениям персонажа сериала.

Асинхронный сервис для чат-бота по сериалу Друзья



Рисунок 6 – Ответ модели до улучшения фактологической связности

Асинхронный сервис для чат-бота по сериалу Друзья

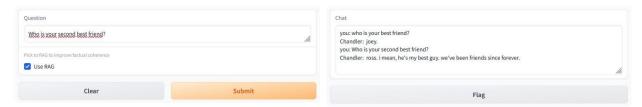


Рисунок 7 – Ответ модели после улучшения фактологической связности

В дальнейшем фактологическую связность можно улучшить, добавляя дополнительную информацию из других источников т.к. статья на википедии содержит только общее описание и не всегда конкретна в части отношений персонажей.

Инференс и валидация модели

Инференс модели реализован в виде асинхронного вебсервиса (до 5 одновременных чатов) на базе gradio и позволяет отображать диалог в виде реального чата. Общая архитектура чат-бота представлена на рисунке 8. На рисунке 9 показан пример одновременного запуска двух чатов в разных окнах.

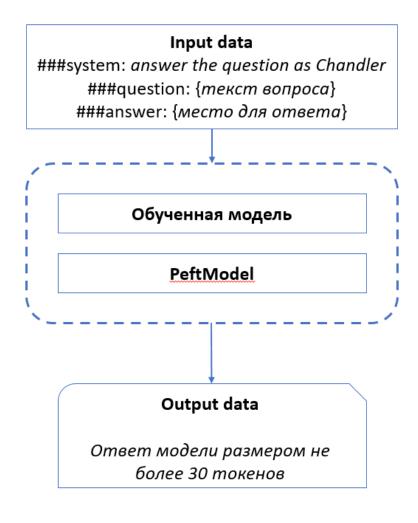


Рисунок 8 – Архитектура чат-бота

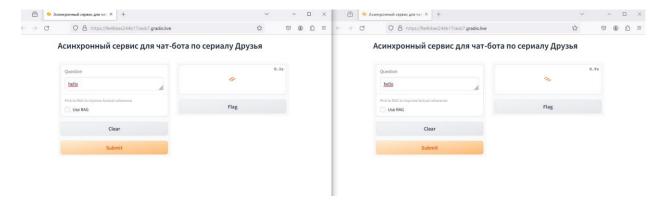


Рисунок 9 – Асинхронный запуск двух чатов

Для валидации результатов выбраны следующие тесты:

1. Простое приветствие ('hello, how are you?')
Проверка ответа бота на простой вопрос и оценка времени работы медленного алгоритма. Результат представлен на рисунке 10. Результат выглядит как продолжение какого-то другого диалога.

Асинхронный сервис для чат-бота по сериалу Друзья

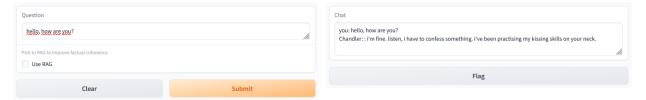


Рисунок 10 – Результат работы чат-бота на тестовой задаче № 1

2. Диалог из нескольких реплик

Проверка работы бота на имитации реального диалога. В качестве реплик старался выбирать те, что спровоцируют отвечать в стиле выбранного персонажа. Результат представлен на рисунке 11. Диалог получился связным и соответствующим персонажу т.к. большую часть сериала они и правда зависали с друзьями в кофейне.

Асинхронный сервис для чат-бота по сериалу Друзья

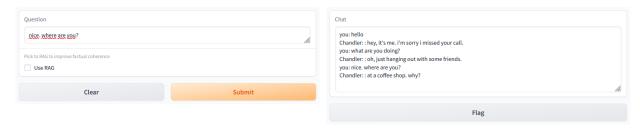


Рисунок 11 – Результат работы чат-бота на тестовой задаче № 2

Выводы

Разработан чат-бот с помощью дообучения модели Phi-2. Проведена работа по улучшению фактологической связности ответов. Реализован асинхронный вебинтерфейс на базе gradio. Работоспособность бота продемонстрирована на тестовых примерах. Качество работы оценивалось исходя из адекватности ответов заданному вопросу.

Инструкция

Запуск чат-бота осуществляется посредством запуска блокнота https://colab.research.google.com/drive/HaFwWL12LMLIdNgq9u1QCkxL87_a9GAx на локальной машине или в google colab. После запуска в последней ячейке появится интерфейс на базе gradio. В левом окне вводятся вопросы, в правом появляется диалог в режиме чата с учетом контекста предыдущих ответов. Чтобы начать диалог заново, забыв контекст, нужно перезапустить ячейку с интерфейсом gradio.